

Titel der großen Studienarbeit

Projektarbeit

des Studienganges **Angewandte Informatik / Betriebliches Informationsmanagement**
an der Dualen Hochschule Baden-Württemberg Mannheim

von

Fabian Brandmüller, Maximilian Ludwig, Kevin Wrona

27. März 2020

Bearbeitungszeitraum
Betreuer der DHBW

23.09.2019 - 20.04.2019
Eckhard Kruse

Erklärung

Ich versichere hiermit, dass ich meine Projektarbeit mit dem Thema: "Titel der großen Studienarbeit" selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe.

Ort

Datum

Unterschrift

Abstract

Inhaltsverzeichnis

1 Einleitung	1
2 Anforderungen	3
2.1 Aufgabenstellung	3
2.2 Usecase	3
2.3 MoSCoW Priorisierung	4
3 Stand der Technik	5
3.1 Gesichtserkennung vs. Emotionserkennung	5
3.1.1 Gesichtserkennung	5
3.1.2 Emotionserkennung	6
3.1.2.1 Emotionen	6
3.1.2.2 Abgrenzung zur Gesichtserkennung	7
3.2 Emotionserkennung mithilfe von Deep Learning	7
3.2.1 Machine Learning - Frameworks	8
3.2.1.1 Dlib	8
3.2.1.2 Keras	9
3.2.1.3 Unterschiede	9
3.2.2 Supervised vs. Unsupervised Learning	9
3.3 Gesichtserkennung mit Opencv	10
3.3.1 Opencv Klassifizierer	10
3.3.1.1 HAAR Cascade Klassifizierer	10
3.3.1.2 Gesichtserkennungs Algorithmen	11
3.3.2 Eingabe Daten	12
4 Ergebnis	14
4.1 Konzept	14
4.1.1 Architektur	15
4.1.1.1 Hardware	15
4.1.1.2 Programmierumgebung	15
4.1.2 Interaktionskonzept	15

4.2	Umsetzung der Lösung	16
4.2.1	Stand-Alone Lösung mit Schwerpunkt OpenCV	16
4.2.1.1	Input GUI	16
4.2.1.2	Dataset	22
4.2.1.3	Training	27
4.2.1.4	Testing	29
4.2.1.5	Optimierung der Lösung	31
4.2.2	Webbasierte Lösung	31
4.2.2.1	Programmierumgebung	31
4.2.2.2	Dataset	32
4.2.2.3	Modell	33
4.2.2.4	Trainieren des Modells	34
4.2.2.5	Testen des Modells	34
4.2.2.6	Webserver	34
4.2.2.7	Jupyter Notebook	34
4.2.2.8	Verzeichnisstruktur	34
4.2.2.9	Alternativ Ansatz zur Pokerface Erkennung	34
5	Diskussion	35
5.1	Reflexion der Ergebnisse	35
5.1.1	Alternativen	35
5.2	Reflexion Vorgehen	35
5.3	Reflexion der Literatur	35
5.4	Offene Implikationen	35
6	Ausblick	35
6.1	Alternative Ansätze zur Umsetzung von Emotionserkennung	36

Abbildungsverzeichnis

- 3.1 Phasen der Gesichtserkennung
Quelle: <https://alitarhini.files.wordpress.com/2010/12/untitled1.png> 5
- 3.2 haar features
Quelle: https://docs.opencv.org/master/dc/d88/tutorial_traincascade.html 11

3.3	RGB Kanäle	
Quelle:	https://www.howtogeek.com/wp-content/uploads/2011/02/sshot-74.png	13
4.1	GUI mit Video Stream der Webcam als Output	18
4.2	GUI mit Video Stream der Webcam und markierten Gesichtern als Output	20
4.3	GUI mit Video Stream der Webcam und markierten Gesichtern und Augen als Output	22
4.4	t	23
4.5	fig:Test	24
4.6	Struktur Emotionsverlauf	25
4.7	Struktur überarbeitetes Dataset	28
4.8	Model Summary with several Layers and I/O Shapes	42

Abkürzungen

1 Einleitung

“Several researchers have stated that facial expression recognition appears to play one of the most important roles in human communication”¹ Dieses Zitat von Katherine B. Leeland gibt einen Einblick in die Relevanz der Emotionserkennung für den Menschen. Fragen zu dieser Thematik stellen sich allerdings nicht erst seit Beginn der Digitalisierung. Bereits Darwin fragte sich, ob von den Gesichtsausdrücken einer Person nicht auch der Emotionale Zustand abgeleitet werden kann.² Einen solchen Zustand von einem Mitmenschen mittels Software abzulesen ist jedoch nicht leicht zu realisieren. Bereits durch kleine Änderungen in der Mimik werden verschiedene Emotionen ausgedrückt. Zum Beispiel indem eine Person die Lippen zusammen presst und die Augen zusammen kneift bei Wut, oder die Mundwinkel nach unten gezogen werden bei Trauer.³ Durch derartige Ausdrücke können Emotionen wie Wut oder Trauer Ausdruck gewinnen. Emotionserkennungssoftware gibt es bereits und wird auch in der Wirtschaft eingesetzt. Die Anwendungsgebiete reichen dabei von Jobinterviews, in denen analysiert wird in wie weit die Bewerber für den jeweiligen Job geeignet sind,⁴ bis hin zur Automobilindustrie. Dort wird mittels geeigneter Sensorik versucht die Emotion und somit der physiologische Zustand des Autofahrers zu analysieren.⁵ Diese Daten legen den Grundbaustein für Warnsysteme, welche den Fahrer darauf hinweisen können, dass sein Zustand ungeeignet zum Betrieb eines Kraftfahrzeugs ist. Jedoch werden solche Einsatzszenarien auch durchaus kontrovers diskutiert. Auf Kritik stößt unter anderem dass die sogenannten ”Basisemotionen” - z.B. Wut, Trauer, Ekel, Freude, Furcht, Überraschung - , die verwendet werden um den KIs Emotionserkennung beizubringen, selbst umstritten sind.⁶ Aber auch ethische Bedenken werden zunehmend geäußert, vor allem bezüglich der Anwendungsgebiete. Denn je nach Emotion die erkannt werden soll, liegt die Fehlerrate sehr hoch. So hat das Fraunhofer Institut, welches an Einsatzgebieten von Emotionserkennung in Fahrzeugen arbeitet, festgestellt, dass eine Emotionserkennung je nach Ziлемotion eine Vorhersagekraft zwischen 6 und 95%

¹Vgl. Leeland, *Face Recognition: New Research*, S. 1.

²Vgl. Leeland, *Face Recognition: New Research*, S. 2.

³Vgl. Li, *Handbook of Face Recognition*, S. 249.

⁴Vgl. Schreiner, *Künstliche Intelligenz: Emotionserkennung will gelernt sein*.

⁵Vgl. Diederichs, *KI-gestützte Emotionserkennung im Fahrzeug aus physiologischen Daten*, Herausforderung.

⁶Vgl. Kuhn, *Emotionen sind schwer definierbar*.

haben kann.⁷ Diese negativen Aspekte treffen jedoch nur teilweise auf das hier behandelte Forschungsprojekt zu, wie im Folgenden dargelegt werden soll: Basierend auf den zuvor genannten Basisemotionen Wut, Frucht, Trauer, Freude, und Ekel soll in dieser Arbeit getestet werden, in wie weit eine technische Vorhersage der Emotionen mittels künstlicher Intelligenz möglich ist. Dies erfolgt am Anwendungsbeispiel der Pokerface Erkennung. Mittels der hier entworfenen technischen Lösung soll daher getestet werden in wie fern ein Pokerface, das auch als ein emotional neutraler Zustand definiert werden kann, erkannt werden kann. Diese Forschungsarbeit hat also nicht das Ziel, dass alle oder eine Emotion korrekt vorhergesagt wird, sondern zu ermitteln wann keine Emotion vorliegt. Das aus dieser Arbeit hervorgehende Prototyp ist dabei jedoch theoretisch gesehen nicht an das hier verwendete Fallbeispiel des Pokerspielens gebunden. Die Grundidee dieses Prototypen lässt einige hypothetische Einsatzszenarien in der Praxis zu. Diese haben eine gewisse Schnittmenge mit denen von "normaler" Emotionserkennungssoftware, jedoch gibt es auch einige weitere. Diese Im Folgenden werden einige denkbare Szenarien expliziert:

- Polizeiverhöre

Es ist denkbar, dass eine erweiterte Form des entwickelten Prototypen bei Polizeiverhören eingesetzt werden könnte. Hierdurch könnten Beamte die Anwendung eines Pokerfaces durch den Beschuldigten erkennen, welches auf eine Lüge hinweisen könnte. Neben der gebräuchlichen Verwendung eines Lügendetektors wäre der Einsatz der in dieser Arbeit erstellten Lösung eine kostengünstige Variante.

- Gerichtsverhandlungen

Das zweite Einsatzgebiet ist ähnlich zu dem ersten. Bei Gerichtsverhandlungen gelten die gleichen Voraussetzungen wie bei einem Verhör der Polizei. Zwar müssen die Vorgeladenen eine eidesstattliche Erklärung abgeben nur die Wahrheit zu sagen, jedoch ist zu bezweifeln ob dies auch immer der Fall ist. Nun soll nicht der Eindruck entstehen dass das hier gebaute Werkzeug ein Lügendetektor ist. Es ist ebenfalls nicht möglich, dass von einem Pokerface immer auf eine Lüge geschlossen werden kann. Jedoch ist ein Pokerface ein Zeichen dafür, dass sich diese Person ihren emotionalen Zustand nicht anmerken lassen möchte. Und dies wiederum deutet eher daraufhin dass die Person nicht die Wahrheit sagt oder nur teilweise.

- Pokerspiel

Wie bereits erwähnt ist dieses Einsatzszenario das Fallbeispiel dieser Arbeit. Dies liegt unter anderem daran, dass der erste Begriff der mit dem Wort Pokerface - bzw. einem emotionslosen Gesichtsausdruck - in Verbindung gebracht wird, das Pokerspiel

⁷Vgl. Diederichs, *KI-gestützte Emotionserkennung im Fahrzeug aus physiologischen Daten*, Ergebnis.

selber ist. Und auch in diesem kann es nützlich sein zu wissen, ob die Kontrahenten ein Pokerface aufsetzen, oder nicht. Denkbar wäre es, dass ein Mitspieler zum Beispiel mittels einer Kamera das Gesicht des Gegenübers scannt und analysiert ob ein Pokerface vorliegt oder nicht, und dementsprechend agiert.

2 Anforderungen

Das nun folgende Kapitel thematisiert die konkrete Aufgabenstellung der Arbeit, so wie eine Anforderungsanalyse mittels MoSCoW Priorisierung.

2.1 Aufgabenstellung

Das Projekt selber wird an der DHBW in Mannheim durchgeführt und von Prof. Dr. Erckhard Kruse betreut. Wie eingangs erwähnt soll mittels künstlicher Intelligenz erkannt werden, ob eine Emotion vorliegt oder nicht. Zur Umsetzung dieser Aufgabe wird eine Bilderkennungssoftware angefertigt, welches ein übermitteltes Bild nach vorhandenen Emotionen analysiert. Sollte keine Emotion durch die Software erkannt werden, wird dem Anwender das Vorhandensein eines Pokerfaces zurück gegeben. Ein konkretes Einsatzgebiet nach Abschluss der Entwicklung ist nicht vorgesehen, da es sich um ein Forschungsprojekt handelt. Jedoch sind wie bereits in der Einleitung beschrieben einige verschiedene Einsatzmöglichkeiten denkbar, an die das Werkzeug leicht angepasst werden kann.

2.2 Usecase

Wie bereits erwähnt ist der hier behandelte Use Case das Pokerspiel selber. An diesem soll ermittelt werden, in wie weit sich Emotionen vorhersagen lassen können, bzw. das Abhandensein von Emotionen. Dieses Fallbeispiel wurde gewählt, da es unter anderem das naheliegendste ist, so wie ein simples und leicht zu konstruierendes Szenario impliziert. Dabei soll mittels einer Kamera ein Bild von einem Pokerspieler aufgenommen werden, und dann mittels dem hier entworfenen Prototypen verarbeitet und analysiert werden. Am Ende soll dann eine Vorhersage der Emotionen getätigt werden die dem Photographen zur Verfügung gestellt wird.

2.3 MoSCoW Priorisierung

Diese Arbeit soll methodisch mit der MoSCoW Priorisierung bearbeitet werden. Diese Art der Priorisierung teilt die zu bearbeitenden Anforderungen in vier Kategorien ein:¹

- Must - Core Anforderungen die unbedingt umgesetzt werden müssen
- Should - Anforderungen die ebenfalls umgesetzt werden müssen, jedoch um Nachhinein noch durch Change Request verändert werden können.
- Could - Anforderungen die nach den Must und Should Anforderungen umgesetzt werden sollen, sofern noch Ressourcen und Zeit vorhanden sind um diese zu bearbeiten
- Won't - Anforderungen die nicht in diesem Projekt bzw. Release erfolgen, jedoch in einer zukünftigen Version bearbeitet werden sollen.

Im Zuge des Projektes wurden die vorhandenen Anforderungen wie folgt anhand der MoSCoW Priorisierung eingeordnet:

- Must
 - Emotionen werden nicht zufällig erkannt
 - Es wird zwischen keine Emotion (Pokerface) und Emotion vorhanden unterschieden
- Should
 - Die Wahrscheinlichkeit zur Erkennung der richtigen Emotion muss über 50% liegen
 - Es können mindestens fünf verschiedene Emotionen erkannt werden
 - Die Erkennung der Emotion darf nicht länger als 30 Sekunden dauern
 - Die Kosten zur Umsetzung der Lösung müssen dem Nutzen gerecht werden?
- Could
 - Bilder können zu Echtzeit analysiert werden
 - Das Trainieren des Modells darf nicht länger als 72 Stunden dauern
 - Eine Oberfläche zur intuitiven Bedienung der Lösung ohne technisches Verständnis muss vorhanden sein
- Won't
 - Neben dem Analysieren von Bildern ist auch die Analyse von Videos möglich

¹vgl. Urs und Roger, *Handbuch Projektmanagement: Agil – Klassisch – Hybrid*, S. 90.

Dabei sollen die einzelnen Anforderungen entsprechend ihrer Priorität abgearbeitet werden. So kann am Ende der Arbeit deutlich besser eingeordnet werden

3 Stand der Technik

In diesem Abschnitt soll der aktuelle Forschungs- und Entwicklungsstand im Bereich Emotionserkennung thematisiert werden. Jedoch muss dafür erst einmal eine Unterscheidung der Begrifflichkeiten Emotionserkennung und Gesichtserkennung erfolgen, da beide Gebiete Überschneidungen haben, jedoch inhaltlich und von ihren Zielen verschieden sind.

3.1 Gesichtserkennung vs. Emotionserkennung

3.1.1 Gesichtserkennung

Gesichtserkennung ist eine Disziplin der Informatik in der es darum geht Gesichter wieder zu erkennen, und gegebenenfalls verschiedenen Personen zuzuordnen. Dabei lässt sich der Prozess der Gesichtserkennung in vier Phasen einteilen, Face "detection", "alignment", "feature extraction" und "matching", wie anhand von Grafik 3.1 sichtbar ist.¹ Die Detection Phase ist dafür verantwortlich um zu erkennen ob Gesichter vorhanden

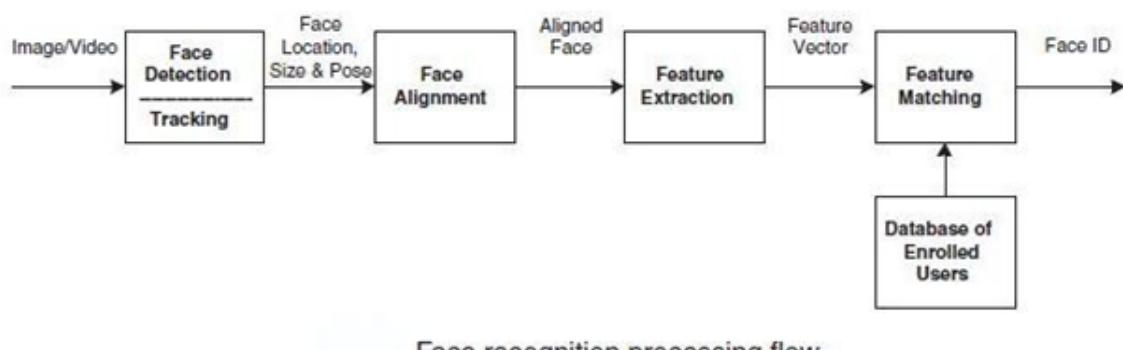


Abbildung 3.1: Phasen der Gesichtserkennung

Quelle: <https://alitarhini.files.wordpress.com/2010/12/untitled1.png>

sind in einem Bild, oder aber Video.² In der darauffolgenden Alignment Phase hin-

¹Vgl. Li, *Handbook of Face Recognition*, S. 2.

²Vgl. Li, *Handbook of Face Recognition*, S. 2.

gegen wird die Lokalisierung der Gesichter genauer, indem Gesichtskomponenten wie Augen, Augenbrauen, oder die Nase genauer lokalisiert werden. Dabei wird das Bild oder Video ebenfalls normalisiert, indem z.B. die Bildbeleuchtung angepasst wird.³ In der Feature extraction hingegen werden die verschiedenen Gesichtskomponenten wie Augen, Nase, Mund, dem Bild oder Video entnommen. Dies ist ein wichtiger Schritt für weitere Prozesse wie Eye Tracking oder Face Tracking. Alternativ kann sogar eine bestimmte Person anhand der extrahierten Merkmale erkannt werden.⁴ In der letzten Phase, dem Matching, geht es darum die gewonnenen Daten mit den in der Datenbank vorhandenen Gesichtern abzugleichen. Wenn eine genügende Übereinstimmung gefunden wurde, wird ein Match mit einer Person ausgegeben.⁵ Die Anwendungsbereiche von Software die Gesichtserkennung ermöglicht ist mannigfaltig. Sie reicht von Applikationen die ein Gerät wie ein Smartphone entsperren, wenn das Gesicht des Besitzers als Match ausgegeben wurde, bis hin zur Anwendung in Verbrechensbekämpfung. In jedem dieser Szenarien wird dabei der oben beschriebene Ablauf durchgegangen, und abhängig vom zu liefernden Ergebnis eine Abschlussaktion vorgenommen.

3.1.2 Emotionserkennung

In diesem Unterkapitel nun sollen Emotionen an sich thematisiert werden, da diese maßgeblich sind für das zu entwickelnde Tool. Eine Definition von Emotionserkennung ist per se nicht schwer zu geben. Prinzipiell beschäftigt sich Emotionserkennung mit der Analyse von Gesichtern und den Emotionen die diese Gesichter darstellen. Jedoch ist der Begriff der Emotionen nicht ganz so einfach zu definieren, wie im folgenden erläutert wird:

3.1.2.1 Emotionen

- Def. von Emotionen

Grundsätzlich gibt es verschiedene Ansätze Emotionen zu definieren und einzuteilen. Eine Variante ist dabei die eingangs erwähnte, nicht ganz unumstrittene Einteilung in Basisemotionen. Eine gängige Einteilung ist dabei die verschiedenen Emotionen in acht Bereiche einzuteilen. Diese Einteilung wurden 1984 von Plutchik postuliert und beinhaltet die Emotionskategorien Angst, Wut, Freude, Trauer, Akzeptanz, Ekel, Erwartung und Überraschung.⁶ Jedoch ist dies nicht die einzige mögliche Einteilung. Als weiteres Beispiel teilte MacLean die Emotionen in lediglich sechs Kategorien ein, welche da wären: Verlangen, Wut, Angst, Niedergeschlagenheit, Freude und Zuneigung.⁷ Wie

³Vgl. Li, *Handbook of Face Recognition*, S. 2.

⁴Vgl. Saranya und Kumar, *Geometric shaped facial feature extraction for face recognition*, Abstract.

⁵Vgl. Li, *Handbook of Face Recognition*, S. 3.

⁶Vgl. Leeland, *Face Recognition: New Research*, S. 3.

⁷Vgl. Leeland, *Face Recognition: New Research*, S. 3.

sich bereits an den beiden Beispielen zeigt, geht die Meinungen der Forscher dabei stark auseinander, welche und wie viele Emotionen zu den sogenannten "Basis Emotionen" gehören. In dieser Arbeit werden die Emotionen in sechs Kategorien eingeteilt, in Wut, Trauer, Freude, Ekel, Überraschung und Neutral. Diese Einteilung entspricht an sich keiner gängigen Einteilung, jedoch wurde diese aus den folgenden Gründen gewählt: Die hier genannten Emotionen lassen sich gut anhand von Bildern erlernen, da diese zum Teil komplementär und somit eindeutig sind. Es ist aber auch einfacher Testdatensätze zu bekommen für ein freudiges Gesicht, oder ein überraschtes, als ein Gesicht mit dem emotionalen Ausdruck Akzeptanz. Des Weiteren wurde der Ausdruck "Neutral" hinzugefügt. Neutral repräsentiert ein emotionsloses Gesicht, und somit nach Definition einem Pokerface. Zudem sind die gewählten Emotionen häufig bei dem Test Usecase dieser Arbeit anzutreffen, dem Texas Holdem Poker.

3.1.2.2 Abgrenzung zur Gesichtserkennung

Der grundlegende Unterschied zwischen Emotions- und Gesichtserkennung liegt nun darin, dass bei der Emotionserkennung selber nicht die agierende Person im Vordergrund steht, sondern die Aktion die sie ausführt. Bei der Gesichtserkennung hingegen spielt lediglich die Rolle wer eine Aktion ausführt, und ob es einen Treffer in der Datenbank gibt, oder nicht. Wegen dieser Unterschiede ist auch die technische Realisierung eines Prototypen, vor allem im Bezug auf die Architektur, durchaus unterschiedlich. Dies ist jedoch ebenso von den unterschiedlichen Anwendungsszenarien der beiden Verfahren bedingt. Denn diese sind ebenso verschieden. Während Gesichtserkennung eher in den Bereich IT-Security oder aber Social Media (Snapchat Filter) eingesetzt wird, ist Emotionserkennung eher Informationsgenerierend. Zum Beispiel kann durch Emotionserkennung Informationen zugänglich werden wie das Befinden eines Individuums ist, ob emotional betroffen ist, oder aber nicht emotional betroffen wirken möchte und ein Pokerface aufsetzt. Wegen dieser signifikanten Unterschiede kann daher trotz der Gemeinsamkeiten nicht gesagt werden, dass Emotionserkennung eine Unterkategorie von Gesichtserkennung ist.

3.2 Emotionserkennung mithilfe von Deep Learning

In dem nun folgenden Kapitel wird erörtert wie das Ziel des Prototypen dieser Arbeit - das Erkennen eines Pokerfaces - mittels eines neuronalen Netzes umgesetzte werden kann. Dabei wird weniger auf die generellen Eigenschaften von Neuronalen Netzen Bezug genommen, als auf die in dieser Arbeit spezifischen Aspekte. Diese sind vor allem verschiedene Ansätze und Möglichkeiten mittels Machine Learning eine Emotionserkennungssoftware zu erstellen.

3.2.1 Machine Learning - Frameworks

Um die gegebene Aufgabenstellung der Erkennung von Emotionen mittels der Analyse eines Gesichtes umsetzen zu können, musste ein entsprechendes Framework Anwendung finden, welches den Anforderungen gerecht wird. Maschinelles Lernen gehört in der heutigen Softwareentwicklung zu den beliebtesten Themen, wodurch dieses schnelle regelmäßige Änderungen und Weiterentwicklungen erfährt. Dementsprechend werden auf dem Markt auch zahllose kostenlose wie auch kostenpflichtige Frameworks angeboten. Um nur einige bekannte aufzuzählen fallen darunter OpenCV, TensorFlow oder Pandas. Möchte man nun das geeignete Framework für das eigene Projekt ausfindig machen, muss man das gegebene Angebot nach einigen Kriterien filtern. Als erstes stellt sich die Frage, was für eine Art von Applikation man umsetzen möchte. Soll das Projekt Texte analysieren oder wie im Falle dieses Projektes die Emotionen aus einem gegebenen Bild? Welche Programmiersprache wird innerhalb des Projektes eingesetzt? Zudem sind Informationen zur Lizenz und dem Support wichtig, sowie insbesondere die Community.

Nach entsprechender erster Selektion musste sich schlussendlich zwischen Dlib und Keras entschieden werden, welche für die Umsetzung der Anforderungen dieses Projektes am besten geeignet schienen. Beide Frameworks werden in den folgenden beiden Unterkapitel dem Leser kurz vorgestellt und anschließend wird ein Fazit gezogen, welches der beiden für dieses Projekt am geeignetsten war.

3.2.1.1 Dlib

Dlib ist nach dessen Entwickler Davis King ein modernes C++ Toolkit, welches Machine-Learning Algorithmen und Tools zur Entwicklung komplexer Software enthält um Probleme aus der echten Welt lösen zu können.⁸

Dlib selbst wurde in der Programmiersprache C++ entwickelt und kann durch eine Anbindung auch für Python Projekte eingesetzt werden. Die Software-Bibliothek kann unter den Bedingungen der Boost-Lizenz frei genutzt werden und ist durch entsprechende APIs des jeweiligen Betriebssystems Plattformunabhängig. Ein weiterer Vorteil bietet die Unabhängigkeit der Bibliothek von anderen Bibliotheken. Dlib ist seit dem Jahr 2002 in Entwicklung und bietet dementsprechend unzählige Features an, welche für verschiedenste Einsatzgebiete verwendet werden können, wie numerische und graphische Modell-Algorithmen und vor allem Gesichtserkennung.⁹ Eines der größten Vorteile dieser Bibliothek besteht in der ausführlichen Dokumentation für sämtliche Klassen und Funktionen, wie es nicht häufig der Fall ist für vergleichbare Open-Source

⁸Opala, *Top Machine Learning Frameworks Compared: Scikit-Learn, Dlib, MLlib, Tensorflow, and More*, Vgl.

⁹Opala, *Top Machine Learning Frameworks Compared: Scikit-Learn, Dlib, MLlib, Tensorflow, and More*, Vgl.

Projekte.¹⁰

3.2.1.2 Keras

Die Open-Source Bibliothek Keras wurde im Vergleich zu Dlib im Jahre 2015 von dem Google-Programmierer François Chollet in der Programmiersprache Python entwickelt.¹¹

3.2.1.3 Unterschiede

3.2.2 Supervised vs. Unsupervised Learning

In diesem Abschnitt werden die beiden Ansätze des Supervised bzw. des Unsupervised Learnings evaluiert. Dabei sollen jedoch beide Begriffe nicht noch ausführlich beleuchtet werden. Es ist lediglich zu erwähnen, dass Supervised Learning Algorithmen im Gegensatz zu Unsupervised mit Datensätzen arbeiten, die Labels beinhalten, und so einen Datensatz kategorisieren. Grundlegende Informationen zu den einzelnen Vorgehensweisen können aus den Büchern "Hands-On Unsupervised Learning with Python" von Giuseppe Bonacorso und "Applied Supervised Learning with Python" von Benjamin Johnston und Ishita Mathur entnommen werden. Nun gilt es zu klären, ob sich für die zu Grunde liegende Aufgabe ein Supervised oder Unsupervised Ansatz eher anbietet. Ein Unsupervised Learning Algorithmus würde sich vor allem anbieten, wenn Zusammenhänge zwischen einzelnen Datensätzen gefunden werden sollen, die vielleicht nicht von Anfang an bekannt oder bewusst sind.¹² Supervised Learning Algorithmen hingegen bieten sich vor allem an, wenn es darum geht einen Prozess zu automatisieren oder aus der Wirklichkeit zu replizieren.¹³ Das in dieser Arbeit zu Grunde liegende Problem ist demnach vor allem für Supervised Learning Algorithmen geeignet. Dies liegt zum einen daran, dass jedem Bild eines Menschen eine Basismotion zugeordnet werden kann. Zum anderem ist auch der verwendete Datensatz mit dem das Modell trainiert und getestet werden soll ebenfalls gelabelt. Deshalb bietet sich dieses Verfahren am meisten an. Es wäre auch hypothetisch denkbar einen Unsupervised Learning Algorithmus zu verwenden, aber dieser Ansatz wäre suboptimal, da er nicht dem eigentlichen Use case dieses Ansatzes entspricht.

¹⁰Dlib C++ Library, Vgl.

¹¹Stefan Luber, *Was ist Keras?*, Vgl.

¹²Vgl. Giuseppe, *Hands-On Unsupervised Learning with Python*, S. 21.

¹³Vgl. Johnston und Mathur, *Applied Supervised Learning with Python*, S. 4.

3.3 Gesichtserkennung mit Opencv

In dem nun folgenden Abschnitt wird der theoretische Aspekt der Gesichtserkennung mit dem Tool Opencv erläutert, und die für die Arbeit relevanten Eigenschaften aufgearbeitet.

3.3.1 Opencv Klassifizierer

Opencv stellt verschiedenste Klassifizierer zur Verfügung um die Aufgabe der Gesichtserkennung. Zum einen die sogenannten HAAR-Cascade Klassifizierer, zum anderen dedizierte Gesichtserkennungsalgorithmen. Beide Arten werden im Laufe dieser Arbeit verwendet werden, weshalb es zum besseren Verständnis der Arbeit dienlich ist die Funktionsweise dieser zu beleuchten.

3.3.1.1 HAAR Cascade Klassifizierer

Als Datengrundlage für diese Art der Klassifizierer werden positive Bilder gebraucht - Im Falle der Gesichtserkennung also Bilder mit Gesichtern - sowie negative. Aus diesen werden dann Eigenschaften extrahiert und verarbeitet. Grundsätzlich ist diese Art der Klassifizierung deutlich flexibler als "reine" Gesichtserkennungsalgorithmen. Dies liegt daran, dass Haar Klassifizierungen nicht auf Gesichter beschränkt sind, sondern auf zahlreiche Eigenschaften wie Augen und Münder, oder gänzlich andere Tiere oder Objekte wie Mäuse und Häuser. Der Haar-Cascade Klassifizierer lässt sich dabei in vier Bereiche einteilen.

- Haar feature selection
- Creating Integral Images
- Adaboost Training
- Cascading Classifiers

¹⁴ In dem ersten Schritt werden sogenannte Haar features festgelegt. Diese sind im wesentlichen verschiedenartige Ausschnitte aus den Bildern. Eine beispielhafte Selektion dieser kann der Grafik 3.2 entnommen werden. Wie in der Grafik ebenfalls zu sehen ist, sind diese features alle samt rechteckig. Dies bietet die Möglichkeit die Berechnungen die gemacht werden müssen zu beschleunigen, indem Schritt zwei angewandt wird. die vorliegenden Bilder werden dabei in Integralbilder umgewandelt. Diese werden im folgenden nicht genau expliziert, jedoch werden in Integralbildern vereinfacht gesagt in jedem Punkt des Bildes die Pixelsummen eines Rechteckes gehalten, das vom Ursprung bis zu dem jeweiligen Pixel aufgespannt wird. Bei einem Punkt (x,y) wird also

¹⁴Vgl. Berger, *DEEP LEARNING HAAR CASCADE EXPLAINED*.




Abbildung 3.2: haar features

Quelle: https://docs.opencv.org/master/dc/d88/tutorial_traincascade.html

das Rechteck $(0,0)$, $(x,0)$, $(0,y)$, (x,y) betrachtet.¹⁵ Nun können verschiedene Haar features selektiert werden. Das Problem dabei ist jedoch, dass diese für sich nicht sonderlich aussagekräftig sind. Beispielsweise ein Feature dass die Nasenflügel betrachtet ist nicht in der Lage ein Gesicht wirklich zu erkennen. Um deshalb ein aussagekräftiges Ergebnis zu erzielen werden die besten dieser sogenannten schwachen Klassifizierer zusammengefasst und trainiert, zu einem starken Klassifizierer. Dieser Schritt beschreibt das Adaboost Training.¹⁶ Diese Trainingsart benutzt nun den letzten Teil, das Kaskadieren von Klassifizierern. Im wesentlichen handelt es sich dabei um eine Methode die so schnell wie möglich falsche Bilder, also solche die nicht der gewünschten Klasse entsprechen, auszusortieren. Dabei wird in multiplen Stadien gearbeitet, in denen ein sich verschiebender Rahmen über das Bild gelegt, der wiederum die Größe des Zielbildes hat - Zum Beispiel eines Gesichtes, Auges, Mundes, Wenn nun der Rückgabewert für einen den der Rahmen gerade umfasst negativ ist, wird der Rahmen weiter verschoben. Wenn das Ergebnis jedoch positiv ist, wird das Bild dem nächsten Stadium übergeben.¹⁷

3.3.1.2 Gesichtserkennungs Algorithmen

Der Fisher Face Recognizer ist einer von zwei Gesichtserkennungs Algoritihmen die Opencv mit sich bringt. Sein Gegenstück ist der Eigenface Recognizer, auf dem der Fisher Face Recognizer partiell aufbaut. Aus diesem grund wird zuerst die grunndsätzliche

¹⁵Vgl. *Integralbild*.

¹⁶Vgl. Berger, *DEEP LEARNING HAAR CASCADE EXPLAINED*.

¹⁷Vgl. Berger, *DEEP LEARNING HAAR CASCADE EXPLAINED*.

funktionsweise des Eigenface Algorithmus beleuchtet. Dieser Algorithmus bekommt einen Datensatz von verschiedenen Gesichtsbildern als Eingabeparameter. Der Eigenface Algorithmus stuft dabei verschiedene gesichtskomponenten wichtiger ein als andere. zum Beispiel wenn mehr varianz in den Trainingsdaten gegeben ist im Bereich der Nasen und Augen, und weniger im Bereich der Münden und Stirnen, wird der Algorithmus die Nasen und auch Augen als die sinnvolleren oder wichtigeren Komponenten erachten. Anhand dieser wichtigen Komponenten können dann verschiedene Gesichter erkannt werden.¹⁸ Das Problem dieses Algorithmus ist nun, dass viele Komponenten der Gesichter nicht mehr beachtet werden weil sie insgesamt eine zu niedrige Varianz aufgewiesen haben. Ein anderes Szenario wäre dass eine Komponente ohne Aussagekraft eine sehr große Varianz in den Trainingsdaten enthält. Z.B. Wenn in den Datensätzen eine hohe Varianz der jeweiligen Beleuchtung vorhanden ist, also wenn keine einheitliche Beleuchtung der Bilder vorhanden ist. Die Beleuchtung sagt per se nicht viel über ein Gesicht aus, aber der Eigenface Recognizer würde diese Komponente als sehr wichtig einstufen, was zu Fehlern führen kann.¹⁹ Im Gegensatz zum Eigenface Recognizer arbeitet der Fisherface Algorithmus mit klassifizierten Daten. Daher ist er im Vergleich zum bereits explizierten Eigenface Ansatz ein supervised learning Algorithmus. Dieser supervised Algorithmus verfolgt ebenso den Ansatz dass aus dem Datensatz verschiedene Komponenten extrahiert werden, jedoch wird hierbei keine Gewichtung anhand der Varianz vorgenommen. Dadurch wird das zuvor beschriebene Problem teilweise aufgelöst.²⁰ Teilweise nur deshalb, weil ein Modell welches mit dem Fisherface Algorithmus trainiert wird und nur Bilder als Eingabewerte mit einer hohen Beleuchtung bekommt, auch nur solche Bilder korrekt bewerten kann. Wenn nun ein schlecht beleuchtetes Bild bewertet werden sollte, wird der Algorithmus an seine Grenzen kommen. Dieses Problem kann durch den dritten von Opencv angeboten Gesichtserkennungsalgorithmus ausgeglichen werden, dem sogenannten Local binary patterns histograms Recognizer. Dieser ist jedoch nicht relevant für diese Arbeit, weshalb hier zum weiteren nachlesen auf die Opencv Dokumentation verwiesen wird.²¹ ein weiterer Lösungsansatz wäre hingegen noch die Eingabedaten anzupassen, mit denen das resultierenden Modell trainiert wird. Dazu wird jedoch auf den folgenden Unterpunkt 12 verwiesen

3.3.2 Eingabe Daten

Wie im vorherigen Unterpunkt erwähnt kann das Modell ebenfalls dadurch beeinflusst werden wie der Eingabedatensatz aufgebaut ist. Dabei wird im Folgenden nicht auf den konkreten Datensatz eingegangen, sondern viel mehr auf die Anforderungen an

¹⁸Vgl. *Face recognition using OpenCV and Python*.

¹⁹Vgl. *Opencv Dokumentation*.

²⁰Vgl. *Face recognition using OpenCV and Python*, How to fix this issue.

²¹https://docs.opencv.org/2.4/modules/contrib/doc/facerec/facerec_tutorial.html#local-binary-patterns-histograms

die Beschaffenheit von diesem. Zunächst ist dabei zu beachten, dass es grundsätzlich einige Möglichkeiten gibt die Eingabedaten, in diesem Falle Bilder von Gesichtern, vorab zu bearbeiten. ein wesentlicher Aspekt dabei ist neben dem Anpassen der Bilder auf eine bestimmte Größe auch die Wahl der Farbdarstellung. Dabei geht es weniger darum ob beispielsweise die Bilder im RGB (Rot - Grün - Blau) oder HSV (Hue - Saturation - Value) Farbraum vorliegen, sondern um die generelle Zahl an Kanälen die Informationen von einem Bild beinhalten. Beispielsweise wird bei einer klassischen RGB Darstellung auf drei Kanälen Informationen über das Bild gespeichert. die obige Ab-




Abbildung 3.3: RGB Kanäle

Quelle: <https://www.howtogeek.com/wp-content/uploads/2011/02/sshot-74.png>

Abbildung 3.3 zeigt wie die einzelnen Kanäle arbeiten. Informationen aus dem Grundbild die Rot erscheinen, werden im Roten Kanal besonders hell dargestellt. Ausschnitte aus der originalen Abbildung die blau erscheinen werden im blauen Kanal ebenso heller dargestellt. Analog zu den beiden Beispielen arbeitet ebenso der grüne Kanal. Werden die drei Kanäle wieder miteinander verbunden entsteht das Ausgangsbild. Der Vorteil solcher mehr kanaligen Formate ist, dass für das praktisch alle Informationen aus dem original Bild erhalten bleiben. Der Nachteil jedoch wird deutlich wenn die Farbe für den Anwendungsfall keine, oder eine geringe Rolle spielt. da in dieser Arbeit Emotionen anhand von Gesichtern erkannt werden soll, spielt die Farbe der Bilder selber eine untergeordnete Rolle, da diese keine nützlichen Informationen für das zu berech-

nende Modell enthält. Es wäre sogar kontraproduktiv, dadurch dass mehr Kanäle mit Informationen vorhanden sind, muss auch das Modell mehr Daten bekommen um zu lernen wie die Informationen aus diesen zu verstehen sind. Dies wird auch von dem sogenannten "Fluch der Dimensionalität" beschrieben. Auf den Anwendungsfall bezogen bedeutet dies nur, dass je mehr Eigenschaften ausgewertet werden sollen, desto mehr Daten zum Lernen müssen vorhanden sein. Um dem präventiv entgegenzuwirken, ohne in Verlegenheit zu geraten die Testdatensätze später erweitern zu müssen, können auch Bilder verwendet werden die auf weniger Kanäle an Informationen zurückgreifen. Sogenannte Grayscale oder Graustufen Bilder bieten hier den Vorteil, dass es nicht drei, sondern lediglich einen Farbkanal gibt. In diesem wird ein Wert pro Pixel gespeichert. Je höher dieser Wert, desto weißer der Pixel, je niedriger, desto schwärzer. Dieses Format eignet sich bestens für die Anwendung für das hier behandelte Modell, da keine wichtigen Informationen entfallen die in einer farbigen Version des Bildes vorhanden während sich aber die Anzahl der Daten verringert die benötigt werden um das Modell erfolgreich trainieren zu können. Dies erhöht wiederum die Chance das zuvor definierte should Kriterium zu erfüllen, welches besagt, dass die Wahrscheinlichkeit zur Erkennung der richtigen Emotion $\geq 50\%$ liegen muss.

4 Ergebnis

In diesem Kapitel wird das Konzept bezüglich der Architektur sowie verwendeter Komponenten und deren Kommunikation dargestellt. Außerdem werden die Aufgrund des erstellten Konzeptes entwickelten Lösungsansätze und Lösungen erläutert. Darin inbegriffen ist vor allem auch das trainierte Modell zum klassifizieren von den vordefinierten Emotionen und das Verifizieren und Testen dieses Modells.

4.1 Konzept

Nachfolgend wird das in der Planungsphase entwickelte Konzept zur Emotionserkennung unter verschiedenen Aspekten erläutert.

4.1.1 Architektur

4.1.1.1 Hardware

Der Einfachheit halber wird als grundlegende Komponente ein handelsüblicher Laptop zum Entwickeln genutzt. Außerdem wird dabei auf das OpenSource Betriebssystem Ubuntu 18.04.4 LTS in der 64-bit Variante zurückgegriffen. Als zugrunde liegende Ressourcen stehen ein 8 GigaByte Arbeitsspeicher sowie ein Intel Core i5-4210 Quadcore Prozessor mit einer Taktfrequenz von 4 x 2,60 GHz zur Verfügung. Des Weiteren kann die dedizierte Grafikkarte GeForce 820M mit einem Grafikkartenspeicher von 2046 MB verwendet werden. Der Festplattenspeicher von 500 GB kann im Umfang dieser Arbeit vernachlässigt werden, da es im Zusammenhang mit Gesichts- bzw. Emotionserkennung primär darauf ankommt, wie viel Rechenleistung zur Verfügung steht und nicht wie groß die Speicherkapazität des Laufwerks ist. Um das rechenintensive Trainieren des Modells zur Emotionserkennung in akzeptabler Zeit zu garantieren, soll die Rechenleistung des Prozessors und der Grafikkarte vollständig genutzt werden können.

4.1.1.2 Programmierumgebung

Aufgrund der Vorkenntnisse und Relevanz innerhalb des Studiums soll die Programmiersprache Python in aktuellster Version (3.6.9) vorrangig verwendet werden, jedoch kann unter gegebenen Umständen auch die Programmiersprache C++ eingesetzt werden, was noch zu prüfen ist. Auf eine bestimmte IDE wie PyCharm, Emacs oder Visual Studio Code wird sich an dieser Stelle nicht festgelegt, da dies jedem Entwickler selbst zu überlassen ist. Diesbezüglich sind nur Einschränkungen aufgrund der gewählten Rechnerarchitektur und der Programmiersprache zu berücksichtigen.

Zur Entwicklung einer Emotionserkennung sollen als grundlegende Komponenten die Programmbibliothek für Bildverarbeitung OpenCV und das Framework Tensorflow bzw. die Deep-Learning-Bibliothek Keras verwendet werden. Da das Einsatzgebiet von OpenCV in der Bildverarbeitung liegt, soll die Bibliothek dazu genutzt werden, den Input so zu verändern, dass dieser vom Modell zum trainieren oder vorhersagen einer oder mehrerer Emotionen verwendet werden kann. Für den wesentlichen Teil der Arbeit, das Entwickeln eines Modells, welches menschliche Emotion anhand eines Bildausschnittes von einem Gesicht erkennen kann, ist die Deep-Learning-Bibliothek Keras zu verwenden.

4.1.2 Interaktionskonzept

Von der Metaebene aus betrachten, steht noch die Planung eines Interaktionskonzeptes aus, welche nun genauer erläutert wird. Die Bildverarbeitungsbibliothek OpenCV soll dazu verwendet werden, eine grafische Benutzeroberfläche (GUI) in Form eines

Fensters zu entwickeln, mit dessen Hilfe dem Nutzer die Möglichkeit geboten wird, entweder Aufnahmen durch die integrierte Webcam selber als Input zu liefern oder dafür ein von ihm gewähltes schon bestehendes Bild auszuwählen. Das vom Nutzer gelieferte Bild soll entsprechend bearbeitet werden, um anschließend eine Emotion zu erkennen und den entstandenen Output an eine durch OpenCV generierte Oberfläche weiterzugeben. In welcher Form der Output dem Nutzer letztendlich dargestellt wird, als Grafik, einfache Textausgabe oder audiovisuell ist noch zu entscheiden.

Zusammenfassend kann man also sagen, dass der Nutzer aufgrund der Übersichtlichkeit und der Einfachheit halber lediglich mit den von OpenCV generierten Oberflächen interagiert und sich zu keinem Zeitpunkt mit der dahinterliegenden Komponente Keras befassen muss.

Es wird sich auch die Option vorbehalten, den Input webbasiert zu liefern und dem Nutzer auch auf gleiche Art und Weise den Output zurückzuliefern. Um die Komplexität des Projektes weiterhin auf die wesentlichen Bestandteile der Emotionserkennung zu beschränken und nicht unnötig zu erhöhen, wird diese Möglichkeit jedoch vorerst nicht weiter berücksichtigt.

4.2 Umsetzung der Lösung

Während der weiteren Ausarbeitung des Konzeptes und der darauf basierenden Umsetzung sind letztendlich zwei verschiedene Lösungen entstanden. Aufgrund von Problemen die innerhalb des Entwicklungsprozesses im Zusammenhang mit dem Hardwaredesign aufgetreten sind, konnte das Projekt so wie es geplant war nicht zu Ende gebracht werden. Da diese Lösung jedoch als Grundlage für die letztendlich finale Lösung diente, werden nachfolgend beide Umsetzungen genauer erläutert.

4.2.1 Stand-Alone Lösung mit Schwerpunkt OpenCV

In diesem Kapitel wird die Umsetzung der auf dem entwickelten Konzept basierenden Lösung näher erläutert. Es handelt sich dabei um den Stand-Alone Laptop mit installiertem Ubuntu 18.04.4 LTS wobei der Input und der Output auf OpenCV GUIs basiert.

4.2.1.1 Input GUI

Als Einstieg in das Themengebiet Emotionserkennung bzw. Gesichtserkennung bietet sich an, sich zuerst mit den Grundlagen der Bildverarbeitung und den Grundlagen von OpenCV vertraut zu machen. Wie bereits im Konzept beschrieben, soll es dem User möglich sein, mithilfe der Webcam und einer grafischen Oberfläche, welche mit OpenCV programmiert wird, ein Bild als Input zu liefern. Wie man in Abbildung

4.1 sehen kann, wird im ersten Schritt die grafische Oberfläche erstellt und der Video Stream der Webcam in der Oberfläche angezeigt.

Listing 4.1: Code für GUI mit Video Stream der Webcam als Output

```
1 import cv2 as cv
2
3 cam = cv.VideoCapture(0)
4 cv.namedWindow("InputGUI1")
5 img_counter = 1
6 while True:
7     ret, img = cam.read()
8     cv.imshow("InputGUI1", img)
9     if not ret:
10         break
11     k = cv.waitKey(1)
12     if k%256 == 27: # ESC pressed, closing the window
13         break
14     elif k%256 == 32: # SPACE pressed, save image as input
15         cv.imwrite("InputGUI{}.png".format(img_counter), img)
16         img_counter += 1
17
18 cam.release()
19 cv.destroyAllWindows()
```

Nachdem man nun auf den Video Stream der Webcam zugreifen und diesen wiedergeben kann, gilt es den relevanten Bildausschnitt, die sogenannte Region Of Interest (ROI), zu identifizieren. Da wir uns im Umfeld der Gesichts- und Emotionserkennung befinden, sind für uns alle Bereiche relevant, die ein menschliches Gesicht enthalten. Standardmäßig stellt OpenCV einige Modelle zur Objekterkennung zur Verfügung, welche problemlos genutzt werden können. Um nun ein vortrainiertes Modell zur Gesichtserkennung von OpenCV einzubinden, kann man folgende Zeile an den Anfang des Codes schreiben:

Listing 4.2: Einbinden eines vortrainierten OpenCV-Modells zur Gesichtserkennung

```
face_cascade = cv.CascadeClassifier('haarcascades/
haarcascade_frontalface_default.xml')
```

Mithilfe der Methode `detectMultiScale` des eingebundenen Modells, können nun die Koordinaten sowie die Höhe und die Breite von jedem in dem Bild gefundenen Gesicht extrahiert werden. Aufgrund dieser Informationen können wir den bisherigen Code



Abbildung 4.1: GUI mit Video Stream der Webcam als Output

nun so erweitern, dass ein Rechteck um jedes gefundene Gesicht im Video Stream der Webcam gezeichnet wird und über die grafische Oberfläche ausgegeben wird. dies sieht dann folgendermaßen aus:

Listing 4.3: Code für GUI mit Video Stream der Webcam und markierten Gesichtern als Output

```
1 import cv2 as cv
2
3 face_cascade = cv.CascadeClassifier('haarcascades/
4     haarcascade_frontalface_default.xml')
5 cam = cv.VideoCapture(0)
6 cv.namedWindow("InputGUI")
7 img_counter = 0
8 while True:
9     ret, img = cam.read()
10    gray = cv.cvtColor(img, cv.COLOR_BGR2GRAY)
```

```

10     faces = face_cascade.detectMultiScale(gray, 1.3, 5)
11     for (x,y,w,h) in faces:
12         img = cv.rectangle(img,(x,y),(x+w,y+h),(255,0,0),2)
13         cv.imshow("InputGUI", img)
14     if not ret:
15         break
16     k = cv.waitKey(1)
17     if k%256 == 27: # ESC pressed, closing the window
18         break
19     elif k%256 == 32: # SPACE pressed, save image as input
20         cv.imwrite("InputGUI{}.png".format(img_counter), img)
21         img_counter += 1
22
23 cam.release()
24 cv.destroyAllWindows()

```

Wie die durch den Code generiert grafischen Oberfläche aussieht, lässt sich der Abbildung 4.2 entnehmen. Nun lässt sich noch darüber diskutieren, ob es weitere besonders zu berücksichtigende ROIs gibt. Im Zusammenhang mit Emotionen können unter anderem die Augen und der Mund eine besondere Rolle spielen, sodass nachfolgend einmal beispielhaft das Hinzufügen eines weiteren Modells zur Erkennung der Augen in jedem bereits entdeckten Gesicht:

Listing 4.4: Einbinden eines vortrainierten OpenCV-Modells zur Augenerkennung

```

eye_cascade = cv.CascadeClassifier('haarcascades/
haarcascade_eye.xml')

```

Um nun alle Augen in einem Bild zu erkennen, kann nun wieder die Methode `detectMultiScale` des Modells genutzt werden. Dem nachfolgenden Codeschnipsel kann man nun entnehmen, wie um alle Augen, die sich in dem Bildausschnitt befinden in dem auch ein Gesicht erkannt wurde, ein grünes Rechteck gezeichnet wird.

Listing 4.5: Zeichnen von Rechtecken um alle erkannten Augen und Gesichter

```

ret, img = cam.read()
gray = cv.cvtColor(img, cv.COLOR_BGR2GRAY)
faces = face_cascade.detectMultiScale(gray, 1.3, 5)
for (x,y,w,h) in faces:
    img = cv.rectangle(img,(x,y),(x+w,y+h),(255,0,0),2)
    roi_gray = gray[y:y+h, x:x+w]
    roi_color = img[y:y+h, x:x+w]
    eyes = eye_cascade.detectMultiScale(roi_gray)

```




Abbildung 4.2: GUI mit Video Stream der Webcam und markierten Gesichtern als Output

```
for (ex ,ey ,ew ,eh) in eyes:  
    cv.rectangle( roi_color ,( ex ,ey ),( ex+ew ,ey+eh ),( 0 ,255 ,0 )  
                ,2)
```

Somit sind wir nun in der Lage, alle relevanten Bereiche zu identifizieren und zu markieren. Um diese relevanten Regionen nun als input zum Vorhersagen einer Emotion für ein Modell nutzen zu können, müssen die entsprechenden Bereiche jedoch erst einmal abgespeichert werden. Um eine Vergleichbarkeit der Bilder untereinander und des zu testenden Bildes zu den trainierten Bildern zu gewährleisten, sollten diese alle das gleiche Format besitzen. Wie bereits in der Theorie erwähnt, ist es außerdem sinnvoll, entsprechende Ausschnitte nicht im Farbmodus abzuspeichern, sondern lediglich als Grayscale-Grafik. Erweitert man den bereits entstandenen Code erneut um die erlauterten Aspekte, sieht dies so aus:

Listing 4.6: Code für GUI mit Video Stream der Webcam und markierten Gesichtern und Augen als Output

```
1 import cv2 as cv
```

```

2
3 face_cascade = cv.CascadeClassifier('haarcascades/
4     haarcascade_frontalface_default.xml')
5 eye_cascade = cv.CascadeClassifier('haarcascades/
6     haarcascade_eye.xml')
7 cam = cv.VideoCapture(0)
8 cv.namedWindow("InputGUI")
9 img_counter = 0
10 while True:
11     ret, img = cam.read()
12     gray = cv.cvtColor(img, cv.COLOR_BGR2GRAY)
13     faces = face_cascade.detectMultiScale(gray, 1.3, 5)
14     for (x,y,w,h) in faces:
15         img = cv.rectangle(img,(x,y),(x+w,y+h),(255,0,0),2)
16         roi_gray = gray[y:y+h, x:x+w]
17         roi_color = img[y:y+h, x:x+w]
18         eyes = eye_cascade.detectMultiScale(roi_gray)
19         for (ex,ey,ew,eh) in eyes:
20             cv.rectangle(roi_color,(ex,ey),(ex+ew,ey+eh)
21                         ,(0,255,0),2)
22         cv.imshow("InputGUI", img)
23         if not ret:
24             break
25         k = cv.waitKey(1)
26         if k%256 == 27: # ESC pressed, closing the window
27             break
28         elif k%256 == 32: # SPACE pressed, save grayscale face as
29             input
30             gray = gray[y:y + h, x:x + w] # Cut the frame to size
31             try:
32                 cv.imwrite("InputGUI{}.png".format(img_counter),
33                             cv.resize(gray, (350, 350)))
34                 img_counter += 1
35             except:
36                 pass
37
38 cam.release()
39 cv.destroyAllWindows()

```

Das daraus resultierende Ergebnis kann man der Abbildung 4.3 entnehmen. Somit ist




Abbildung 4.3: GUI mit Video Stream der Webcam und markierten Gesichtern und Augen als Output

es dem Nutzer möglich, schnell und unkompliziert Bilder mit der Webcam zu machen und dort enthaltene Gesichter so zu speichern, dass sie als Input zum Vorhersagen einer Emotion genutzt werden können.

4.2.1.2 Dataset

Zum Trainieren eines Modells zur Emotionserkennung, wird das sogenannte Cohn-Kanade Dataset zur Analyse von Emotionen verwendet.¹ In dem verwendeten Dataset sind ca. 10000 Grayscale-Bilder enthalten, welche die in 4.1 zu sehenden Emotionen: Es fällt auf, dass sich die dargestellte Anzahl von ca. 325 nutzbaren Bildern stark von der bereits erwähnten Anzahl von 10000 Bildern unterscheidet. Dies liegt daran, dass das Dataset ursprünglich für die Analyse von Emotionen und nicht direkt für die Emotionserkennung entwickelt wurde. Was das kann genau hast, wird durch die Abbildung 4.4 verdeutlicht.

Jeder Datensatz beinhaltet mehrere Bilder, die den Verlauf einer Emotion von Neutral bis hin zur Emotion darstellen. Da dieser Verlauf für die Emotionserkennung

¹Vgl. Cohn, Kanade und Tian, *Comprehensive Database for Facial Expression Analysis*.

Emotion	N
Anger	45
Contempt	18
Disgust	59
Fear	25
Happy	69
Sadness	28
Surprise	83

Tabelle 4.1: Emotionen mit jeweiliger Anzahl an Bildern



Abbildung 4.4: Emotionsverlauf von Neutral zu Disgust

allenfalls für die Klassifizierung innerhalb der jeweiligen Emotion relevant wäre und somit im Umfang dieser Arbeit nicht betrachtet wird, wird nur das jeweils letzte Bild dieses Verlaufs, also die vollständig ausgeprägte Emotion, zum Trainieren des Modells genutzt. Somit ergibt sich der Unterschied von der Anzahl der jeweils letzten Bilder der Verläufe, ca. 325, und der Anzahl der Gesamtbilder aller Verläufe, ca. 10000. Zur Verzeichnisstruktur des Datasets kann sagen, dass es grundsätzlich zwei verschiedene Ordner gibt. In einem Ordner befinden sich alle Bilder, also die Verläufe der Emotionen und in dem anderen befinden sich mit der gleichen Struktur die dazugehörigen Emotionen. Stellt man die Struktur der beiden Ordner beispielhaft als Verzeichnisbaum dar, sieht dies folgendermaßen aus:

Wie man den Verzeichnisbäumen entnehmen kann, ist die Struktur in beiden Ordner identisch. In der ersten Ebene befinden sich Ordner jeweils mit 'S' aufgeteilt nach Personen. Innerhalb jeder dieser Personenordner gibt es einen oder mehrere weitere Ordner. Diese Ordner auf der 2. Ebene sind dreistellig aufsteigend numeriert und beinhalten jeweils einen Emotionsverlauf. Im Sachzusammenhang bedeutet dies, dass jede Person eine oder mehrere verschiedene Emotionsverläufe darstellt. Die Syntax der Dateinamen in den




Abbildung 4.5: fig:Test




Abbildung 4.6: Struktur Emotionsverlauf

aufsteigend nummerierten Ordner, die letztendlich den Emotionsverlauf beinhalten, ist <Personenordner>_<Emotionsverlaufsordner>_<Pos. im Verlauf>.png wobei die Position im Verlauf 8-stellig ist. Nimmt man die in Abbildung 4.4 als Grundlage, könnten die einzelnen Dateinamen zu den Bildern wie im Verzeichnisbaum 4.6 aussehen. Aus der dargestellten Struktur des Ordners in dem sich sämtliche Bilder befinden und den jeweiligen Dateinamen lassen sich keinerlei Rückschlüsse auf die dargestellten Emotionen ziehen. Um herauszufinden welche Emotion durch welchen Emotionsverlauf dargestellt wird, muss man in das entsprechende Verzeichnis in dem Ordner mit den gelabelten Emotionen wechseln. Dort befindet sich dann eine Textdatei, die den selben Dateinamen hat, wie das letzte Bild aus dem dazugehörigen Emotionsverlauf. In dieser Datei befindet sich dann eine Fließkommazahl, die für die jeweilige Emotion in Tabelle 4.1 steht. Um nun herauszufinden welche Emotion durch den in 4.6 dargestellt wird, schaut man in das Verzeichnis emotions/S005/001/, in dem sich die Datei S005_001_00000011.txt befindet. In dieser Datei würde dann 3.000000e+00 stehen, was sich gemäß der Tabelle mit **Disgust** gleichsetzen lässt.

Um später ein vernünftiges supervised learning auf Grundlage des Dataset durchzuführen, wird eine eigene Verzeichnisstruktur erstellt, die jedes letzte Bild eines Emotionsverlaufs sortiert nach Emotion beinhaltet. Der folgenden Code automatisiert das überarbeiten und sortieren des Datasets und erweitert dieses um die Emotion **Neutral**, da jedes erste Bild eines Emotionsverlaufs als neutrale Ausgangslage dient.

Listing 4.7: Dataset sortieren und überarbeiten

```
1 import glob, os, shutil, sys
2
3 if not os.path.exists("source_emotion"):
4     print("source_emotion wurde nicht gefunden!")
5     sys.exit(0)
6 if not os.path.exists("source_images"):
7     print("source_images wurde nicht gefunden!")
8     sys.exit(0)
9 if os.path.exists("sorted_set"):
10    shutil.rmtree("sorted_set")
11
12 # setup destination directory
13 emotions = ["neutral", "anger", "contempt", "disgust", "fear", "happy", "sadness", "surprise"]
14 os.makedirs("sorted_set")
15 for emotion in emotions: # create folder for each emotion
16     os.makedirs("sorted_set/%s" % emotion)
17
18 participants = sorted(glob.glob("source_emotion/*")) # Returns a list of all folders with participant numbers
19 for participant in participants:
20     part = "%s" % participant[-4:] # store current
21         participant number
22     sessions = sorted(glob.glob("%s/*" % participant))
23     participant_neutral_handled = False
24     for session in sessions: # Store list of sessions for
25         current participant
26         files = sorted(glob.glob("%s/*" % session))
27         for file in files:
28             current_session = file[20:-30]
29             file = open(file, 'r')
30             # store emotion as int
31             emotion = int(float(file.readline()))
32             # get belonging emotion sequence
33             images = sorted(glob.glob("source_images/%s/%s/*" % (part, current_session)))
34             # copy last image from sequence to sorted set
35             sourcefile_emotion = images[-1]
```

```

34     destination_emotional = "sorted_set/%s/%s" % (
35         emotions[emotion], sourcefile_emotion[25:])
36     shutil.copyfile(sourcefile_emotion,
37                     destination_emotional)
38     # handle the neutral image only if not done for
39     # this participant before
40     if not participant_neutral_handled:
41         sourcefile_neutral = images[0]
42         destination_neutral = "sorted_set/neutral/%s"
43         % sourcefile_neutral[25:]
44         shutil.copyfile(sourcefile_neutral,
45                         destination_neutral)
46         participant_neutral_handled = True
47
48 print("sorted_set with emotion images created!")

```

Das überarbeitete und sortierte Dataset, welches nun als neue Grundlage für die Stand-Alone Lösung dient, sieht dann so aus:

4.2.1.3 Training

OpenCV stellt verschiedene Klassifizierer zur Verfügung, jedoch wird sich in diesem Abschnitt immer auf das Supervised Learning des FisherFaceRecognizer bezogen, welcher mit dem im vorherigen Schritt präparierten Dataset trainiert wird. Da das Dataset schon sortiert und vorbereitet wurde, ist es nun sehr leicht eine Methode zu schreiben, die ein Array mit Trainingsdaten und ein Array mit den zugehörigen Labels liefert. Aufgrund der Verzeichnisstruktur des Datasets kann man über alle Emotionsordner iterieren und alle Grayscale-Bilder in das Array mit den Trainingsdaten einlesen und die jeweilige Emotion in das Array mit den Labels einlesen. Dabei ist jedoch zu beachten, dass die Labels Integer-Werte aufsteigend mit 0 beginnend sein müssen. Das heißt, die Ordnernamen, welche die Emotionen als Text sind, müssen in Integer-Werte konvertiert werden, indem man z.B. den jeweiligen Index in dem Emotions-Array

Listing 4.8: Emotions-Array

```

emotions = ["neutral", "anger", "contempt", "disgust", "fear", "
            happy", "sadness", "surprise"]

```

nimmt. Setzt man dies um, entsteht folgender Code:

Listing 4.9: Trainingsdaten als Arrays extrahieren

```

def get_training_sets():
    training_data = []

```




Abbildung 4.7: Struktur überarbeitetes Dataset

```

training_labels = []
for emotion in emotions:
    emotion_number = emotions.index(emotion)
    training = glob.glob("dataset/%s/*" % emotion)
    for item in training:
        training_data.append(cv.imread(item))
        training_labels.append(emotion_number)
return training_data, training_labels

```

Da wir nun die erforderlichen Arrays mit Trainingsdaten und Labeln erzeugen können, beschäftigen wir uns als nächstes mit dem zu trainierenden Klassifizierer, dem sogenannten FisherFaceRecognizer. Im folgenden werden zwei Methoden dargestellt, mit denen dieser erzeugt und trainiert werden kann.

Listing 4.10: Methoden zum Erstellen und Trainieren eines FisherFaceRecognizer

```

def create_fishface():
    return cv.face.FisherFaceRecognizer.create()

def train_classifier(fishface, data, labels):
    fishface.train(data, np.asarray(labels))
    return fishface

```

Da nun alle erforderlichen Einzelschritte definiert sind, können wir diese nun zusammenfügen.

Listing 4.11: Erstellen und Trainieren eines FisherFaceRecognizer

```

training_data, training_labels = get_training_sets()
fishface = create_fishface()
train_classifier(fishface, training_data, training_labels)

```

Wie dem Code zu entnehmen ist, stellt die `FisherFaceRecognizer`-Klasse die Methoden `create()` und `train(InputArray data, InputArray labels)` zur Verfügung, sodass der Großteil der Komplexität des gesamten Trainingsprozesses bei dem Vorbereiten des Datasets liegt.

4.2.1.4 Testing

Das Testen des im vorherigen Schritt trainierten Modells kann aufgrund der Vorarbeit ebenfalls sehr schnell implementiert werden. Aufgrund der wie sich später herausstellte sehr geringen Datengrundlage und der Should-Anforderung gemäß MoSCoW Priorisierung, dass die Wahrscheinlichkeit zu Erkennung der richtigen Emotion über 50% liegen soll, wird anstatt der üblichen Aufteilung des Datasets in Trainings- und Testdaten das

komplette Dataset als Trainingsdaten genutzt. Daraus ergibt sich dann, dass ein anderes Verfahren zum Testen des Klassifiziers gefunden werden muss. Somit wird zum Testen des Modells eine grafische Oberfläche erstellt, die im speziellen als Echtzeit-analyse der Emotionen fungiert. Hierzu kann ein Großteil des Codes genutzt werden, der als Vorarbeit im Bereich der Input GUI implementiert wurde. Der Ablauf eines konkreten Tests ist dann das Starten der Oberfläche, welche den Video Stream der Webcam ausgibt und gleichzeitig jedes Einzelbild vom Modell analysieren lässt. Dies geschieht wie ebenfalls bereits beschrieben durch das Ausschneiden des Gesichtes und das anschließende konvertieren in das Grayscaleformat sowie daraufhin das wesentliche Vorhersagen einer Emotion. Das Gesicht wird dann mit einem Rechteck markiert und darüber wird die vorhergesagte Emotion ausgegeben. Verändert man den Code der Input GUI nur geringfügig und erweitert ihn um das Vorhersagen der Emotion und das Schreiben der vorhergesagten Emotion auf den Output Video Stream, dann erhält man folgendes Ergebnis:

Listing 4.12: Klassifizierer mit der Input GUI testen

```
def test_classifier(fishface):
    cam = cv.VideoCapture(0)
    cv.namedWindow("Classifier Test")
    while True:
        ret, img = cam.read()
        gray = cv.cvtColor(img, cv.COLOR_BGR2GRAY)
        faces = face_cascade.detectMultiScale(gray, 1.3, 5)
        for (x, y, w, h) in faces:
            img = cv.rectangle(img, (x, y), (x + w, y + h),
                               (255, 0, 0), 2)
            gray = gray[y:y + h, x:x + w]
            try:
                gray = cv.resize(gray, (350, 350))
                prediction, conf = fishface.predict(gray)
                cv.putText(img, emotions[prediction], (x, h),
                           cv.FONT_HERSHEY_SIMPLEX, 1.0, (255, 0, 0),
                           lineType=cv.LINE_AA)
            except:
                pass
    cv.imshow("Classifier Test", img)
    if not ret:
        break
```

```

k = cv.waitKey(1)
if k%256 == 27: # ESC pressed , closing the window
    cam.release()
    cv.destroyAllWindows()
    break

```

4.2.1.5 Optimierung der Lösung

Durch das Testen des Modells konnte festgestellt werden, dass trotz der vergrößerten Menge an Daten zum Trainieren, die Genauigkeit der Vorhersagen deutlich unter 50% liegt. Aufgrund dieser Tatsache wird versucht, den Trainingsprozess zu optimieren. Die Möglichkeiten zum komplexen Konfigurieren eines Modells in OpenCV sind begrenzt, so dass das Konfigurieren eines Modells, welches wesentlich mehr Features der Emotion analysiert als zuvor, erschwert wird. Außerdem würde sich dann die Tatsache bemerkbar machen, dass OpenCV keine Möglichkeit bietet, die Rechenleistungen der CPU und der GPU zu kombinieren. Daraus würde sich ein sehr langwieriger Trainingsprozess ergeben, was nicht mehr den Anforderungen entspricht. Daher wird zunächst versucht, den Prozess in eine extra dafür vorgesehene Bibliothek auszulagern, wobei die Entscheidung auf die Keras-API des Tensorflow-Frameworks gefallen ist. Auf die genaue funktionsweise von Keras wird in einem späteren Kapitel näher eingegangen. An dieser Stelle bleibt dann nur noch zu bemerken, dass die Installation von Keras und das Einbinden benötigter Komponenten erfolgreich durchgeführt werden konnte, jedoch die Ausführen der benötigten Komponenten wegen einer nicht unterstützten Prozessorarchitektur bzw. eines nicht unterstützten Chipsets nicht möglich war. Aufgrund der benötigten Ressourcen und der mit Tensorflow kompatiblen Architektur wurde sich deshalb für eine webbasierte Cloudlösung entschieden.

4.2.2 Webbasierte Lösung

Trotz der augetretenen Komplikationen bei der Entwicklung einer Stand-Alone Lösung muss an dieser Stelle erwähnt werden, dass große Teile, gerade im Bereich des Inputs und Outputs wiederverwendet werden. Die auf Grundlage der Stand-Alone Version entwickelte webbasierte Lösung wird nachfolgend genauer erläutert.

4.2.2.1 Programmierumgebung

Zusätzlich zu den bereits erwähnten Gründen für die Entscheidung der Programmiersprache Python ist noch die Wiederverwendbarkeit der bisher entwickelten Lösung zu nennen. Da weiterhin Python verwendet wird, stellt sich nun die Frage, mit welcher Entwicklungsumgebung gearbeitet wird. Da nun auf einer Cloud-Infrastruktur entwickelt

wird, sind die reinen grafischen Umgebungen wie Visual Studio Code oder PyCharm nicht zu empfehlen. Aufgrund vieler Vorteile, die dem entsprechenden Kapitel zu entnehmen sind und der ebenfalls bereits erwähnten Relevanz innerhalb des Studiums wird zum weiteren Entwickeln die Open-Source Webapplikation Jupyter Notebook verwendet. Die finale Version wird jedoch später mit den durch Jupyter Notebook exportierbaren Python-Skripten und nicht direkt über das Jupyter Notebook laufen. OpenCV, die Programmbibliothek für Bildverarbeitung und Keras, die Deep-Learning-Bibliothek, werden weiterhin für die bereits beschriebenen Zwecke verwendet.

4.2.2.2 Dataset

Im Zuge der vertieften Recherche nach Keras und der direkten Verwendung im Bereich Gesichts- und Emotionserkennung wurde ein besseres Dataset gefunden, als bisher verwendet wurde. Das Dataset gehört zu einer Open-Source Facial Expression Recognition auf Kaggle.² Kaggle ist eine Online-Community deren Hauptzweck es ist, Data-Science-Wettbewerbe auszuschreiben, an denen jeder interessierte teilnehmen kann. Außerdem ermöglicht die Platform Datensätze zu finden und zu veröffentlichen und ggf. Modelle auszuprobieren oder ebenfalls zu veröffentlichen. Vereinfacht kann man sagen, dass Kaggle ein virtueller Treffpunkt für Data-Scientists in den Bereichen Maschinelles Lernen und KI-Entwicklung ist.

Betrachten wir nun das im Projekt verwendete Dataset. Das Dataset umfasst 35887 Datensätze, die allesamt gelabelt sind. Dabei wird das Set in Trainingsdaten, Public-Testdaten und Private-Testdaten unterteilt, wobei 80% aller Werte auf das Trainingsset entfallen und jeweils 10% auf die Testsets. Die Unterteilung der Testdaten in Public und Private ist dabei nur im direkten Zusammenhang mit dem Kaggle-Wettbewerb von Relevanz, da ein Set zum Testen des Modells für die Entwickler selbst ist und das Andere, um einen Sieger der Challenge auszumachen. Da wir mit unserem Modell nicht an der Facial Emotion Recognition Challenge teilnehmen, können wir die beiden Testsets zu einem großen zusammenfassen. Damit erhalten wir 28709 Datensätze zum Trainieren des Modells und 7178 Datensätze zum Testen. Aufgrund der Menge an Daten werden diese nicht wie beim anderen Dataset in einer Ordnerstruktur mit entsprechend vielen Bilddateien zur Verfügung gestellt, sondern als Comma-Separated-Values (.csv). Dabei handelt es sich um eine Art Tabelle, deren Struktur beispielhaft der Tabelle 4.2 zu entnehmen ist. Die Spalte `emotion` kann dabei Werte von 0 bis 6 annehmen, wobei sich insgesamt 7 verschiedene Werte ergeben, die den Emotionen entsprechend der Tabelle 4.3 zugeordnet werden können. Außerdem werden in der Tabelle die absoluten und relativen Häufigkeiten der Emotionswerte dargestellt, da diese für spätere Optimierungen relevant sind. Betrachten wir nun die anderen Spalten. In der

²FER-Challenge.

emotion	pixels	Usage
0	70 80 82 72 58 58 60 63 54 58 60 48 89 115 121 119 115 110 98 ...	Training
0	151 150 147 155 148 133 111 140 170 174 182 154 153 164 173 178 ...	Training
2	231 212 156 164 174 138 161 173 182 200 106 38 39 74 138 161 ...	Training
4	24 32 36 30 32 23 19 20 30 41 21 22 32 34 21 19 43 52 13 26 40 ...	Training
6	4 0 0 0 0 0 0 0 0 0 0 3 15 23 28 48 50 58 84 115 127 137 142 ...	Training
2	55 55 55 55 55 54 60 68 54 85 151 163 170 179 181 185 188 188 ...	Training
4	20 17 19 21 25 38 42 42 46 54 56 62 63 66 82 108 118 130 139 ...	Training
3	77 78 79 79 78 75 60 55 47 48 58 73 77 79 57 50 37 44 56 70 80 ...	Training
0	254 254 254 254 254 249 255 160 2 58 53 70 77 76 75 78 68 18 32 ...	PublicTest
0	170 118 101 88 88 75 78 82 66 74 68 59 63 64 65 90 89 73 80 80 ...	PrivateTest

Tabelle 4.2: Struktur des CSV-Datasets der FER-Challenge


Wert	Emotion	H_n	h_n
0	Angry	4953	13,80%
1	Disgust	547	1,52%
2	Fear	5121	14,27%
3	Happy	8989	25,05%
4	Sad	6077	16,93%
5	Surprise	4002	11,15%
6	Neutral	6198	17,27%

Tabelle 4.3: Zuordnung und Häufigkeiten der Emotionen

Spalte **pixels** befinden sich die eigentlichen Bilddaten als Pixelwerte, die lediglich mit einem Leerzeichen getrennt in einem String dargestellt werden. In Tabelle 4.2 wird nur ein kleiner Ausschnitt der insgesamt 2304 Pixelwerte pro Datensatz angezeigt, wobei jedes Pixel Werte von 0 bis 255 annehmen kann. Die Anzahl von 2304 Pixeln ergibt sich durch die Länge und die Breite der Bilder von jeweils 48 Pixel mal 48 Pixel. Bevor man die Bilddaten in Form des Strings aus Pixeln für das Modell nutzen kann, müssen diese erst entsprechend formatiert und ungeformt werden, aber dazu später mehr. Die letzte der Tabelle zu entnehmende Information befindet sich in der Spalte **Usage**. Dort wird jedem Datensatz zugeordnet, ob er im Zuge des Wettbewerbes zum Trainieren, zum privaten Testen oder zum öffentlichen Testen verwendet wird.

4.2.2.3 Modell

Nachfolgend wird das für die Emotionserkennung erstellte Modell mit den jeweils einzelnen Layern näher erläutert und 4.8



4.2.2.4 Trainieren des Modells

4.2.2.5 Testen des Modells

4.2.2.6 Webserver

4.2.2.7 Jupyter Notebook

4.2.2.8 Verzeichnisstruktur

4.2.2.9 Alternativ Ansatz zur Pokerface Erkennung

Die nun vorgestellte Lösung zur Analyse der Emotionen eines Subjektes weiß jedoch eine Schwachstelle auf. Sie ist nur darauf ausgelegt ein einzelnes Bild zu analysieren und setzt dieses nicht in einen zeitlichen Kontext. Dies ist auch zur Erkennung eines Pokerfaces nicht optimal, da von einem einzelnen Bild nur partiell darauf geschlossen werden kann, dass ein Pokerface vorliegt. Man nehme zum Beispiel an, dass das Pokerface ein geübten Pokerspielers nicht dadurch gekennzeichnet ist, dass er permanent einen neutralen Gesichtszug annimmt, sondern ständig den gleichen annimmt. Dieses Szenario kann nicht mit der jetzigen Lösung abgedeckt werden. Daher bietet sich hier an eine alternativen Ansatz zu fahren. Dieser besteht im Grunde daraus, dass die Bilder die an den Server zu evaluieren des emotionalen Zustandes noch in einen zeitlichen Kontext gesetzt werden. Die Grundidee dazu ist, dass die einzelnen Ergebnisse der Vorhersagen der Bilder über einen gewissen Zeitraum gespeichert werden. Mit diesen gespeicherten Daten wird dann ermittelt, wie stark sich die einzelnen Bilder hinsichtlich der Emotionen von einander unterscheiden. Da die Rückgabewerte des trainierten Modells numerisch sind, fällt es recht einfach Unterschiede auszumachen.

Umsetzung Realisiert wird dieser Ansatz durch ein Rahmenprogramm. Dieses greift dabei auf die Webcam des Computers zu und nimmt in einem geregelten Intervall Bilder auf. Diese werden dann wiederum an den bereits erläuterten Flask Server geschickt.

5 Diskussion

Das nunmehr letzte Kapitel soll sich mit der kurzen Zusammenfassung der Ergebnisse des letztens Teils und deren Bewertung widmen. Des Weiteren sollen die angewandten Methoden reflektiert werden, offene Fragen beantwortet und auch weitere Punkte aufgezeigt werden die verbessert oder noch implementiert werden können. Dazu soll zunächst die Ergebnisse kurz zusammengefasst werden.

5.1 Reflexion der Ergebnisse

5.1.1 Alternativen

5.2 Reflexion Vorgehen

Mehr darauf eingehen dass das Kontrovers ist und auch die Basisemotionen kontrovers sind – aber keine andere Möglichkeit vorhanden

5.3 Reflexion der Literatur

Bezüglich der Literatur ergeben sich nun einige Schwierigkeiten. Dies liegt unter anderem daran, dass das generelle Thema der Gesichts und Emotionserkennung immer noch vor allem aus psychologischer Sicht in der Literatur behandelt wurde. Zwar gibt es Fachbücher auch aus informationstechnischer Sicht, welche ebenfalls in dieser Arbeit verwendet wurden.

5.4 Offene Implikationen

6 Ausblick

6.1 Alternative Ansätze zur Umsetzung von Emotionserkennung

In diesem Abschnitt nun werden verschiedene alternative Ansätze dargestellt und expliziert, die dazu verwendet werden können um Emotionen zu erkennen. Dieses Unterkapitel beschäftigt sich mit alternativen Ansätzen zu den bereits explizierten Basisemotionen. Diese sind wie bereits erwähnt umstritten, was die Frage zulässt warum diese überhaupt verwendet werden sollten. Ein weiterer kreativer Ansatz zur Erkennung von Emotionen wäre die Analyse der Stimmlage. Dieser Ansatz beruft sich darauf, dass das Sprachzentrum eines Menschen einer der wichtigsten Aspekte der Kommunikation und somit auch der Preisgabe von Informationen über den emotionalen Zustand eines Individuums ist.¹ Dieser Ansatz ist jedoch nicht zielführend, da hier hauptsächlich die Stimme analysiert wird. Von einer Stimme kann nun auf eine Emotion geschlossen werden. Für den Usecase ist dieser Ansatz allerdings ungeeignet, aus folgenden Gründen: Es kann möglich sein eine Emotion anhand der Sprache zu erkennen. Das Äquivalent eines Pokerfaces wäre dementsprechend eine neutrale Stimmlage, welche keine Emotionen suggeriert. Nun kann aber keine Aussage getroffen werden aus welchen Gründen eine Person neutral spricht. Es könnte von einem Pokerface stammen, oder einer monotonen Sprechweise, oder einen gelangweilten Gemütszustand. Dies ist nicht eindeutig identifizierbar. Gleiches könnte nicht über ein neutrales Gesicht gesagt werden, da dies gemeinhin als Pokerface bezeichnet wird. Ein weitere Ansatz wäre die Analyse der derzeit vernommenen Musik. Diese kann einem bestimmten Gemütszustand zugesprochen werden, welches auf eine aktuelle Emotion übertragbar ist.² Ziel dieses Forschungszweiges ist es daher die hinter Liedern oder Klängen stehenden Emotionen zu ermitteln und diese entsprechend zu kategorisieren. Dieser Ansatz erscheint zunächst durchaus interessant, hat jedoch genauso Nachteile wie die Analyse von Emotionen anhand von Bildern die Basisemotionen zeigen. Dieser liegt hier unter anderem in der Genauigkeit der Analysen. So z.B. lieferte ein Testprojekt an der Russischen HSE (Higher School of Economics) das Ergebnis von einer maximalen Genauigkeit von 71%.³ In dem Versuchsaufbau wurden Spektrogramme von Klangfragmenten ausgewertet und versucht mittels Neuronalen Netzen eine Klassifikation der hinter dem Klang liegenden Emotion zu erreichen.⁴ Der generelle Ansatz anhand von Musik die Emotion eines Individuums

¹Vgl. Rao und Koolagudi, *Emotion Recognition using Speech Features*, Abstract.

²Vgl. Yang und Chen, *Music Emotion Recognition*, S. 1.

³Vgl. Popova, Rassadin und Ponomarenko, *Emotion Recognition in Sound*, Abstract.

⁴Vgl. Popova, Rassadin und Ponomarenko, *Emotion Recognition in Sound*, Abstract.

abzulesen ist zwar praktikabel und von dem Versuchsaufbau auch vergleichbar zu dem Ansatz bereits gelabelte Bilder zu verwenden. Jedoch lässt sich auf diese Weise aus zwei Gründen nicht die eigentliche Zielaufgabenstellung ableiten, das Erkennen eines Pokerfaces. Zum einen handelt es sich in dieser Arbeit um eine visuelle Problemstellung, in welcher das Erkennen des Gemütszustandes anhand des Gesichtsausdruckes erkannt werden soll, also einem vorhandenen bzw. nicht vorhandenen Pokerface. Zum anderen würde die Analyse von Musik einen Rückschluss auf den allgemeinen Gemütszustand des Betroffenen folgern und nicht eine kurzzeitige Stimmungsschwankung aufgrund beispielsweise eines schlechten Blattes, wie in diesem Usecase.

Literatur


Literaturquellen


- [Giu19] Bonaccorsor Giuseppe. *Hands-On Unsupervised Learning with Python*. Auflage 1. Birmingham: Packt Publishing Ltd, 2019. ISBN: 978-1789349276.
- [JM19] Benjamin Johnston und Ishita Mathur. *Applied Supervised Learning with Python*. Auflage 1. Birmingham: Packt Publishing Ltd, 2019. ISBN: 978-1789955835.
- [Lee08] Katherine B. Leeland. *Face Recognition: New Research*. 1. Aufl. Nova Science Publishers INC, 2008. ISBN: 978-16045646625.
- [Li05] Anil K. Li Stan Z.and Jain. *Handbook of Face Recognition*. Springer Science und Business Media, 2005. ISBN: 978-0387405957.
- [PRP17] Anastasiya S. Popova, Alexandr G. Rassadin und Alexander A. Ponomarenko. *Emotion Recognition in Sound*. Cham, Deutschland: Springer Verlag, 2017. ISBN: 978-3319666037.
- [RK12] K. Sreenivasa Rao und Shashidhar G. Koolagudi. *Emotion Recognition using Speech Features*. 1. Auflage. Berlin, Deutschland: Springer Science und Business Media, 2012. ISBN: 978-1461451433.
- [SK17] R Benedict Saranya und J. Satheesh Kumar. *Geometric shaped facial feature extraction for face recognition*. Coimbatore - India: IEEE, 2017. ISBN: 978-1509037698.
- [UR18] Schneider Patrickand Witschi Urs und Wüst Roger. *Handbuch Projektmanagement: Agil – Klassisch – Hybrid*. Auflage 4. Sebastopol: SSpringer Gabler”, 2018. ISBN: 978-3662578773.
- [YC11] Yi-Hsuan Yang und Homer H. Chen. *Music Emotion Recognition*. Boca Raton Florida: CRC Press, 2011. ISBN: 978-1466508927.

Sonstige Quellen

- [17a] *Face recognition using OpenCV and Python*. <https://www.superdatascience.com/blogs/opencv-face-recognition>. Einsichtnahme: 23.03.2020. 2017.

- [17b] *Integralbild*. <https://de.wikipedia.org/wiki/Integralbild>. Einsichtnahme: 22.03.2020. 2017.
- [19a] *Dlib C++ Library*. <http://dlib.net/>. Einsichtnahme: 07.03.2020. 2019.
- [19b] *Opencv Dokumentation*. <https://docs.opencv.org/2.4/modules/contrib/doc/facerec/facerec.html>. Einsichtnahme: 23.03.2020. 2019.
- [Ber18] Will Berger. *DEEP LEARNING HAAR CASCADE EXPLAINED*. <http://www.willberger.de/haar-explained/>. Einsichtnahme: 22.03.2020. 2018.
- [CKT00] Jeffrey F. Cohn, Takeo Kanade und Yingli Tian. *Comprehensive Database for Facial Expression Analysis*. <http://www.consortium.ri.cmu.edu/ckagree/>. Einsichtnahme: 07.03.2020. 2000.
- [Die20] Dr. Frederik Diederichs. *KI-gestützte Emotionserkennung im Fahrzeug aus physiologischen Daten*. <https://www.hci.iao.fraunhofer.de/de/Human-Centered-AI/feinfuehlige-technik/KI-gestuetzte-Emotionserkennung.html>. Einsichtnahme: 24.01.2020. 2020.
- [Kuh19] Johannes Kuhn. *Emotionen sind schwer definierbar*. <https://www.sueddeutsche.de/digital/software-emotionen-simulation-ki-1.4377004-2>. Einsichtnahme: 24.01.2020. 2019.
- [Opa18] Mateusz Opala. *Top Machine Learning Frameworks Compared: Scikit-Learn, Dlib, MLlib, Tensorflow, and More*. <https://www.netguru.com/blog/top-machine-learning-frameworks-compared>. Einsichtnahme: 07.03.2020. 2018.
- [Sch19] Maximilian Schreiner. *Künstliche Intelligenz: Emotionserkennung will gelernt sein*. <https://mixed.de/kuenstliche-intelligenz-emotionserkennung-will-gelernt-sein/>. Einsichtnahme: 24.01.2020. 2019.
- [Ste18] Nico Litzel Stefan Luber. *Was ist Keras?* <https://www.bigdata-insider.de/was-ist-keras-a-726546>. Einsichtnahme: 24.01.2020. 2018.








Abbildung 4.8: Model Summary with several Layers and I/O Shapes